

# 1 Laporan Proyek Crips DM

## 1.1 Domain Proyek

Transfer data di berbagai platform, terutama pada aplikasi berbasis pengenalan wajah, semakin berkembang pesat. Identifikasi karakteristik demografis seperti usia dan jenis kelamin menjadi langkah awal yang penting untuk memberikan pengalaman yang lebih personal dan relevan bagi pengguna. Teknologi ini kini banyak diterapkan di berbagai bidang, seperti keamanan, pemasaran, dan pengalaman pengguna, di mana sistem dapat mengenali data demografi hanya dari gambar wajah. Penelitian ini berfokus untuk mengembangkan sebuah model yang dapat mendeteksi usia dan jenis kelamin dengan memanfaatkan model pra-latih seperti VGG16 yang telah disesuaikan untuk tugas klasifikasi jenis kelamin dan estimasi usia secara bersamaan. Pendekatan transfer learning digunakan, di mana model ini akan dilatih lebih lanjut agar dapat beradaptasi dengan dataset spesifik, dengan output berupa akurasi untuk klasifikasi jenis kelamin dan nilai Mean Absolute Error (MAE) untuk estimasi usia. Pendekatan ini memungkinkan pengembangan model yang lebih efisien dan akurat dalam mengenali karakteristik demografis dari gambar wajah.

## 1.2 Business Understanding

Dalam era digital saat ini, teknologi pengenalan wajah semakin banyak digunakan dalam berbagai aplikasi, mulai dari keamanan hingga pemasaran. Misalnya, sistem ini dapat membantu dalam pengawasan keamanan di tempat umum, verifikasi identitas dalam transaksi keuangan, dan personalisasi pengalaman pengguna di platform digital. Dengan menggunakan model yang mampu mengenali wajah secara akurat, bisnis dapat meningkatkan efisiensi operasional, mengurangi risiko penipuan, dan memberikan layanan yang lebih baik kepada pelanggan. Oleh karena itu, memahami kebutuhan bisnis dan bagaimana teknologi pengenalan wajah dapat memenuhi kebutuhan tersebut adalah langkah awal yang krusial dalam pengembangan sistem ini. Dengan pendekatan yang tepat, proyek ini berpotensi memberikan nilai tambah yang signifikan bagi organisasi, baik dalam hal peningkatan keamanan maupun peningkatan pengalaman pengguna.

### 1.2.1 Problem Statements

- Peningkatan kebutuhan akan sistem yang mampu mengenali karakteristik demografis dari gambar wajah untuk mendukung berbagai aplikasi.
- Kurangnya solusi yang efisien dan akurat dalam mendeteksi informasi usia dan jenis kelamin secara bersamaan.
- Tantangan dalam mengembangkan model yang dapat memberikan hasil prediksi dengan kecepatan tinggi tanpa mengorbankan akurasi.
- Perlunya teknologi yang dapat diandalkan untuk mendukung personalisasi layanan, analisis data demografis, dan verifikasi identitas.

### 1.2.2 Goals

- Mengembangkan model pembelajaran mesin yang mampu mendeteksi dan mengenali karakteristik demografis, seperti usia dan jenis kelamin, secara akurat dari gambar wajah.
- Memberikan solusi yang dapat diterapkan di berbagai sektor, seperti keamanan, personalisasi layanan, dan analisis data demografis.

### 1.2.3 Solution Statements

- Mengembangkan model pembelajaran mesin berbasis transfer learning dengan memanfaatkan arsitektur VGG16 sebagai backbone.
- Menggunakan pendekatan multi-output untuk menghasilkan prediksi klasifikasi jenis kelamin dan estimasi usia secara bersamaan.
- Memanfaatkan embedding wajah yang dihasilkan oleh model sebagai representasi fitur yang kuat untuk meningkatkan akurasi dan efisiensi prediksi.
- Merancang model yang dapat dengan mudah diimplementasikan untuk berbagai kebutuhan.
- Melakukan evaluasi model menggunakan metrik akurasi untuk klasifikasi jenis kelamin. Dan Mean Absolute Error (MAE) untuk estimasi usia.
- Memastikan solusi yang diusulkan memenuhi standar keandalan, kecepatan, dan akurasi untuk aplikasi di dunia nyata.

## 1.3 Data Understanding


Data yang digunakan bersifat publik.[Kaggle]

<https://www.kaggle.com/datasets/jangedoo/utkface-new>


### 1.3.1 Overview Data

- Nama Dataset :  
UTKFace
- Total Dataset :  
3517 foto dengan format jpg dengan 2 index, 0 dan 1 dimana index 0 menunjukkan usia dan index 1 menunjukkan jenis kelamin, dan jenis kelamin dilabeli dengan 0 dan 1 untuk 0 sebagai laki-laki dan 1 sebagai perempuan.


Gambar 1. Isi dari dataset UTKFace



Gambar 2. Jumlah data setiap pembagian usia




Gambar 3. Jumlah data setiap pembagian jenis kelamin



Pada Gambar 2 dan 3 dapat dilihat jumlah antar kelas tiap data usia dan jenis kelamin.

## 1.4 Alur Klasifikasi

Gambar 4. Metode yang diusulkan




Pada gambar 4 menjelaskan :

Proses klasifikasi dimulai dengan mengimport library yang diperlukan lalu memasukkan dataset yang akan digunakan untuk pelatihan model. Setelah dataset dimuat, dilakukan ekstraksi fitur untuk mengidentifikasi karakteristik penting dari data. Proses ini melibatkan penyesuaian dimensi gambar, peningkatan kualitas, atau transformasi lain yang bertujuan memperjelas informasi yang relevan bagi model. Selanjutnya, model dilatih menggunakan metode deep learning berbasis Convolutional Neural Network (CNN) dengan memanfaatkan model pre-trained VGG16 melalui teknik transfer learning. Teknik ini memungkinkan model memanfaatkan pengetahuan dari model sebelumnya, kemudian dilakukan fine-tuning untuk menyesuaikan model dengan dataset yang spesifik. Beberapa kustomisasi pada arsitektur CNN juga diterapkan untuk meningkatkan performa model. Dataset yang digunakan dibagi menjadi dua bagian, yaitu 80% untuk data pelatihan dan 20% untuk data validasi. Proses pelatihan dilakukan dengan 30 epoch agar model dapat belajar secara optimal dan mencapai parameter terbaik. Setelah pelatihan selesai, model dievaluasi pada data validasi, dengan hasil yang divisualisasikan dalam grafik akurasi dan loss akurasi untuk prediksi jenis kelamin (gender), serta grafik Mean Absolute Error (MAE) untuk prediksi usia (age).

## 1.5 Data Preparation

Gambar 5. Dataset yang sudah memiliki label



Dataset yang didapatkan yaitu dataset publik dari kaggle yang dimana sudah memiliki label unik, untuk memudahkan dalam melakukan deteksi usia dan jenis kelamin. Dalam pelabelan dataset diketahui pemberian nama pada dataset dengan aturan angka depan sebagai indikasi umur, angka tengah sebagai indikasi gender dengan 0 adalah laki-laki dan 1 adalah perempuan, sedangkan untuk angka dibelakangnya cuma angka biasa dan tidak akan mempengaruhi dalam pelatihan model dari datasetnya.

Contoh membaca dataset dapat dijelaskan seperti berikut :

3\_0\_0\_201701102129.. = dataset dengan umur 3 tahun dan gender laki-laki.

3\_1\_0\_201612191545.. = dataset dengan umur 3 tahun dan gender perempuan.

Pseudocode untuk memecah dataset menjadi 2 label dilakukan sebagai berikut:

1. Inisialisasi daftar kosong:

- `image\_paths` untuk menyimpan path gambar.
- `age\_labels` untuk menyimpan label usia.
- `gender\_labels` untuk menyimpan label jenis kelamin.

2. Lakukan perulangan untuk setiap file dalam direktori `BASE\_DIR`:

- Buat path lengkap gambar dan simpan ke dalam `image\_path`.
- Pisahkan nama file menggunakan pemisah underscore ('\_').
- Ambil informasi usia dari bagian pertama nama file dan ubah menjadi tipe integer.
- Ambil informasi jenis kelamin dari bagian kedua nama file dan ubah menjadi tipe integer.
- Tambahkan `image\_path` ke dalam daftar `image\_paths`.
- Tambahkan usia yang diambil ke dalam daftar `age\_labels`.
- Tambahkan jenis kelamin yang diambil ke dalam daftar `gender\_labels`.

Pseudocode diatas menjelaskan bagaimana alur untuk memecah satu foto pada dataset agar memiliki dua label yaitu label age yang diindikasikan dengan angka 0 dan label gender yang diindikasikan dengan angka 1. Untuk melakukan deteksi age dan gender akan dilakukan dua cara yaitu penggunaan klasifikasi untuk gender dan regresi untuk age.

Deteksi usia dilakukan dengan klasifikasi karena usia sering dikelompokkan ke dalam kategori tertentu, misalnya anak-anak, remaja, dewasa, atau lansia. Hal ini membuat klasifikasi lebih efektif karena model hanya perlu memutuskan kategori mana yang paling sesuai dengan input. Selain itu, hasil klasifikasi lebih mudah diinterpretasikan karena langsung menunjukkan kategori yang jelas, bukan nilai usia yang kontinu.

Sementara itu, deteksi gender dilakukan dengan regresi karena pendekatan ini memungkinkan prediksi dalam bentuk nilai kontinu, misalnya antara 0 hingga 1. Hal ini berguna jika gender dipandang sebagai spektrum atau jika ingin memprediksi probabilitas secara langsung. Dengan regresi, hasil yang dihasilkan lebih fleksibel dan bisa memberikan informasi probabilistik yang lebih halus dibandingkan klasifikasi yang kaku pada kategori tertentu.

## 1.6 Modelling

Untuk pemodelan yang dipakai dalam membantu algoritma Deep Learning CNN ini, kami menggunakan model Transfer Learning VGG16. Transfer learning adalah teknik dalam deep learning di mana model yang telah dilatih pada dataset besar digunakan kembali sebagai titik awal untuk tugas baru. VGG16 adalah salah satu model deep learning berbasis arsitektur Convolutional Neural Network (CNN) yang dirancang oleh tim Visual Geometry Group (VGG) di University of Oxford. Model ini terdiri dari 16 lapisan (berisi convolutional, fully connected, dan pooling layers) yang sudah dilatih sebelumnya pada dataset ImageNet, yang mencakup jutaan gambar dalam ribuan kategori. Kelebihan transfer learning dengan VGG16 terletak pada efisiensi dan keandalannya. Model ini menghemat waktu dan sumber daya dengan memanfaatkan fitur yang sudah dilatih pada dataset besar seperti ImageNet, sehingga cocok untuk dataset kecil dan mengurangi risiko overfitting. Selain itu, VGG16 fleksibel untuk berbagai tugas seperti klasifikasi atau deteksi objek dengan hanya memodifikasi lapisan akhirnya. Stabilitas dan keandalannya yang telah terbukti menjadikannya pilihan efektif dalam deep learning.

Gambar 6. Penggunaan arsitektur VGG16 sebagai deteksi usia dan jenis kelamin berdasarkan wajah seseorang.

| Layer (type)   | Output Shape         | Param #   | Connected to       |
|--|----------------------|-----------|--------------------|
| input_layer (InputLayer)   | (None, 128, 128, 3)  | 0         | -                  |
| block1_conv1 (Conv2D)  | (None, 128, 128, 64) | 1,792     | input_layer[0][1]  |
| block1_conv2 (Conv2D)  | (None, 128, 128, 64) | 36,528    | block1_conv1[0][0] |
| block1_pool (MaxPooling2D)   | (None, 64, 64, 64)   | 0         | block1_conv2[0][0] |
| block2_conv1 (Conv2D)  | (None, 64, 64, 128)  | 73,856    | block1_pool[0][1]  |
| block2_conv2 (Conv2D)  | (None, 64, 64, 128)  | 147,584   | block2_conv1[0][0] |
| block2_pool (MaxPooling2D)   | (None, 32, 32, 128)  | 0         | block2_conv2[0][0] |
| block3_conv1 (Conv2D)  | (None, 32, 32, 256)  | 295,168   | block2_pool[0][1]  |
| block3_conv2 (Conv2D)  | (None, 32, 32, 256)  | 590,880   | block3_conv1[0][0] |
| block3_conv3 (Conv2D)  | (None, 32, 32, 256)  | 590,880   | block3_conv2[0][0] |
| block3_pool (MaxPooling2D)   | (None, 16, 16, 256)  | 0         | block3_conv3[0][0] |
| block4_conv1 (Conv2D)  | (None, 16, 16, 512)  | 1,180,160 | block3_pool[0][1]  |
| block4_conv2 (Conv2D)  | (None, 16, 16, 512)  | 2,359,808 | block4_conv1[0][0] |
| block4_conv3 (Conv2D)  | (None, 16, 16, 512)  | 2,359,808 | block4_conv2[0][0] |
| block4_pool (MaxPooling2D)   | (None, 8, 8, 512)    | 0         | block4_conv3[0][0] |
| block5_conv1 (Conv2D)  | (None, 8, 8, 512)    | 2,359,808 | block4_pool[0][1]  |
| block5_conv2 (Conv2D)  | (None, 8, 8, 512)    | 2,359,808 | block5_conv1[0][0] |
| block5_conv3 (Conv2D)  | (None, 8, 8, 512)    | 2,359,808 | block5_conv2[0][0] |
| block5_pool (MaxPooling2D)   | (None, 4, 4, 512)    | 0         | block5_conv3[0][0] |
| flatten (Flatten)  | (None, 8192)         | 0         | block5_pool[0][1]  |
| dense (Dense)  | (None, 256)          | 2,097,408 | flatten[0][1]      |
| dense_1 (Dense)  | (None, 256)          | 2,097,408 | flatten[0][1]      |
| dropout (Dropout)  | (None, 256)          | 0         | dense[0][1]        |
| dropout_1 (Dropout)  | (None, 256)          | 0         | dense_1[0][1]      |
| gender_out (Dense)   | (None, 1)            | 257       | dropout[0][1]      |
| age_out (Dense)  | (None, 1)            | 257       | dropout_1[0][1]    |
| Total params: 10,910,016 (72.14 MB)<br>Trainable params: 10,910,016 (72.14 MB)<br>Non-trainable params: 0 (0.00 B) |                      |           |                    |



Tabel 1. Parameter Pelatihan

| Parameter        | Deskripsi   |
|------------------|---|
| Arsitektur Model | VGG16 dengan transfer learning, ditambah layer kustom untuk deteksi jenis kelamin dan estimasi usia   |
| Optimizer        | Adam dengan learning rate 0.00001 (1e-5)  |
| Loss Function    | - Binary Crossentropy untuk keluaran jenis kelamin<br>- Mean Absolute Error (MAE) untuk keluaran usia |
| Jumlah Epoch     | 30 epoch  |
| Batch Size       | 32  |
| Validation Split | 20% dari dataset digunakan untuk validasi   |
| Metrics          | - Akurasi untuk keluaran jenis kelamin<br>- Mean Absolute Error (MAE) untuk keluaran usia             |

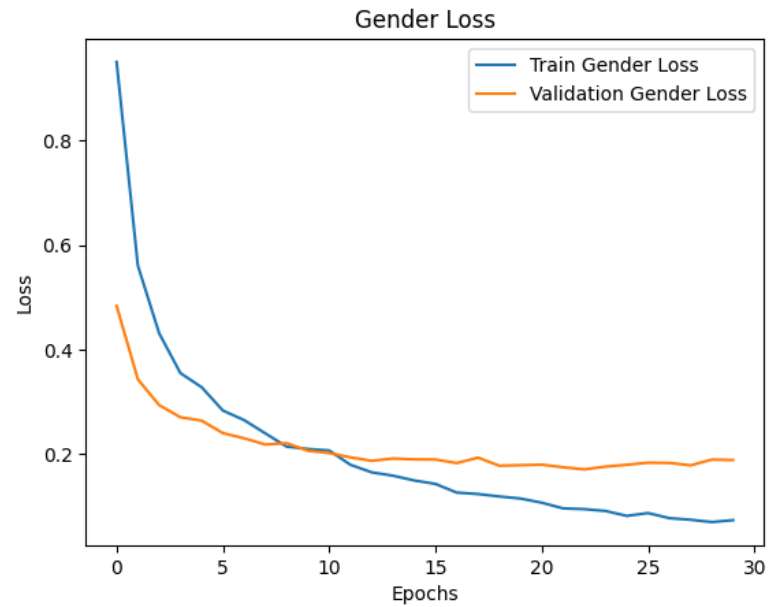
## 1.7 Evaluation & Result

Dari hasil dan evaluasi dari memprediksi usia dan jenis kelamin menggunakan algoritma Deep Learning CNN dan model Transfer Learning VGG16 yang dipakai, pada percobaan kali ini bisa didapatkan hasil dari Gender yaitu Accuracy yang mencakup Precision, Recall, F1-Score, dan Confusion Matrix. Serta hasil dari Age berupa Age Regression Report yang mencakup Mean Absolut Error (MAE), Root Mean Squared Error (RSME), dan R-squared.

### 1.7.1 Gender Report


Algoritma dari Deep Learning CNN yang diuji menggunakan model Transfer Learning VGG16 ini dalam melakukan klasifikasi jenis kelamin sangat bagus dalam memberikan hasil yang dapat dilihat dari grafik akurasi gender dan loss akurasi gender dibawah ini.

Gambar 7. Plot gender loss



Pada gambar 7 loss yang dihasilkan sudah dapat dibilang cukup baik

Gambar 8. Plot gender akurasi




Pada gambar 8 akurasi yang dihasilkan memiliki nilai akurasi yang baik dengan nilai sekitar 98 dan validasi 90.

Dibuktikan dengan hasil berupa akurasi, precision, recall, F1-score, dan confusion matrix untuk klasifikasi jenis kelamin / gender, dijelaskan pada gambar 9 dan 10.

Gambar 9. Klasifikasi report gender

| Gender Classification Report: |           |        |          |         |
|-------------------------------|-----------|--------|----------|---------|
|                               | precision | recall | f1-score | support |
| Male                          | 0.97      | 0.99   | 0.98     | 348     |
| Female                        | 0.99      | 0.97   | 0.98     | 356     |
| accuracy                      |           |        | 0.98     | 704     |
| macro avg                     | 0.98      | 0.98   | 0.98     | 704     |
| weighted avg                  | 0.98      | 0.98   | 0.98     | 704     |

Gambar 10. Confusion matrix gender




Berdasarkan classification report dan confusion matrix pada gambar 9 dan 10, performa model dalam tugas klasifikasi jenis kelamin sangat baik dengan akurasi mencapai 98%. Nilai precision, recall, dan f1-score yang konsisten tinggi yaitu lebih dari sama dengan 0.97 untuk kedua kelas menunjukkan bahwa model mampu mengenali data asli secara akurat, baik untuk kelas "Male" maupun "Female". Hal ini mengindikasikan keseimbangan prediksi, tanpa adanya bias signifikan terhadap salah satu kelas, serta kemampuan generalisasi model yang kuat.

Pada confusion matrix, mayoritas prediksi berada di diagonal (true positives), yang berarti model secara konsisten memprediksi kelas yang benar. Kesalahan prediksi (false positives dan false negatives) juga tergolong sangat rendah, dengan hanya 24 kesalahan untuk "Male" yang diprediksi sebagai "Female" dan 57 kesalahan untuk "Female" yang diprediksi sebagai "Male". Hal ini mendukung evaluasi dari classification report, menunjukkan model sangat andal untuk klasifikasi gender dengan kesalahan minimal.

Meskipun begitu untuk mencapai hasil 100% sempurna tanpa kesalahan masih belum bisa di dapat dengan model yang dibuat untuk pelatihan, mungkin ada beberapa faktor yang mempengaruhi antara lain seperti noise dalam data, distribusi data yang tidak sepenuhnya representatif, batasan dalam kapasitas generalisasi model, atau bahkan kesalahan labeling dalam dataset. Tetapi ini sudah menunjukkan bahwa model yang dilatih sudah bisa bekerja secara efisien dan sangat handal dalam hal klasifikasi jenis kelamin.

### 1.7.2 Age Report

Gambar 11. Plot MAE akurasi



Gambar 12. Klasifikasi report age

```
Age Regression Report:  
Mean Absolute Error (MAE): 3.54  
Root Mean Squared Error (RMSE): 5.66  
R-squared: 0.94
```

1. Mean Absolute Error (MAE):

MAE mengukur rata-rata kesalahan absolut antara nilai sebenarnya (ground truth) dan nilai prediksi. Nilai ini memberikan gambaran seberapa jauh rata-rata prediksi model dari nilai yang sebenarnya. Pada laporan ini, MAE adalah 3.54, artinya rata-rata kesalahan prediksi usia model adalah sekitar 3,54 tahun.

2. Root Mean Squared Error (RMSE):

RMSE mengukur akar dari rata-rata kuadrat kesalahan, memberikan bobot lebih besar pada kesalahan yang lebih besar dibandingkan MAE. Nilai ini biasanya lebih sensitif terhadap outlier. RMSE pada laporan ini adalah 5.66, menunjukkan bahwa sebagian besar prediksi model memiliki kesalahan rata-rata sekitar 5,66 tahun.

3. R-squared ( $R^2$ ):


$R^2$  mengukur seberapa baik model menjelaskan variabilitas data. Nilainya berkisar antara 0 hingga 1, dengan 1 menunjukkan model yang sempurna.  $R^2$  sebesar 0.94 pada laporan ini berarti model mampu menjelaskan 94% variabilitas data usia, yang menunjukkan performa sangat baik.

Laporan regresi ini menunjukkan performa model yang sangat baik untuk prediksi usia. MAE yang relatif rendah (3.54) menunjukkan bahwa rata-rata kesalahan prediksi usia cukup kecil dan masih dalam batas wajar. RMSE yang sedikit lebih tinggi (5.66) menunjukkan adanya beberapa kesalahan yang lebih besar, meskipun tetap terkendali. Nilai  $R^2$  yang tinggi (0.94) menegaskan bahwa model dapat menjelaskan sebagian besar variabilitas data usia, menunjukkan bahwa model ini sangat andal untuk tugas regresi usia. Namun, untuk meningkatkan akurasi lebih lanjut, akan dilakukan evaluasi terkait penggunaan dataset yang lebih besar dan beragam untuk mencakup rentang usia dan kondisi pencahayaan yang lebih luas. Selain itu, menyesuaikan arsitektur model agar lebih spesifik untuk tugas prediksi usia, atau menggunakan teknik augmentasi data untuk memperkaya variasi dalam data pelatihan, juga meminimalkan noise pada data, seperti memastikan label usia benar dan gambar berkualitas tinggi.


### 1.7.3 Hasil Prediksi

Penambahan hasil prediksi ini dilakukan untuk melakukan tes model agar dapat diketahui hasil prediksi yang sesuai dan tidak sesuai dengan dataset originalnya.


Gambar 12. Contoh Klasifikasi gender dan age yang sesuai



Gambar 13. Contoh Klasifikasi gender sesuai dan age kurang sesuai



Gambar 14. Contoh Klasifikasi gender sesuai dan age sangat jauh berbeda



## 1.8 Kesimpulan

Dalam penelitian ini dapat disimpulkan sebagai berikut :

1. Penggunaan algoritma Deep Learning CNN mampu Memperbaiki kinerja model dengan memanfaatkan arsitektur yang sudah terbukti efektif, seperti VGG16, yang telah terlatih pada dataset besar, dan memungkinkan peningkatan efisiensi serta akurasi dalam tugas klasifikasi dan estimasi.
2. Pendekatan multi-output model memungkinkan klasifikasi jenis kelamin dan estimasi usia dilakukan secara bersamaan, meningkatkan efisiensi sistem.

## 1.9 Saran

Penelitian selanjutnya dapat difokuskan pada implementasi model deteksi usia dan jenis kelamin secara real-time melalui pengembangan aplikasi yang mampu memproses input langsung dari kamera atau perangkat lain. Langkah ini mencakup optimasi model agar efisien dijalankan pada perangkat dengan spesifikasi rendah, seperti smartphone atau perangkat IoT, tanpa mengorbankan akurasi prediksi. Selain itu, dapat dilakukan eksplorasi teknik optimasi seperti quantization atau pruning untuk memperkecil ukuran model dan mempercepat proses inferensi. Model juga dapat dikembangkan lebih lanjut untuk mengenali atribut tambahan, seperti ekspresi wajah atau emosi, guna memperluas penggunaannya dalam bidang keamanan, pemasaran, atau interaksi manusia-mesin. Validasi performa model pada data real-time dengan kondisi lingkungan yang beragam, seperti pencahayaan berbeda atau sudut pandang wajah yang variatif, juga penting dilakukan untuk memastikan keandalannya di berbagai skenario dunia nyata.

## 1.10 Referensi

- [1] Jangedoo, "UTKFace Dataset (New Version)," Kaggle. [Online]. Available: <https://www.kaggle.com/datasets/jangedoo/utkface-new>. [Accessed: Dec. 27, 2024].
- [2] "UTKFace Dataset Resources," Google Drive. [Online]. Available: <https://drive.google.com/drive/folders/1ibLop1YDtPmhyhrOGH0fp2ZrDoFG-yuD>. [Accessed: Dec. 27, 2024].
- [3] R. A. Smith, "Deep Learning for Facial Age and Gender Classification," ProQuest Dissertations and Theses, 2019. [Online]. Available: <https://search.proquest.com/openview/fcc9c274f00c0018060b5b1fa086e440/1?pq-origsite=gscholar&cbl=2026366&diss=y>. [Accessed: Dec. 27, 2024].
- [4] M. A. Wijaya and A. K. Pratama, "Penerapan Deep Learning pada Prediksi Usia dan Jenis Kelamin Menggunakan Dataset Wajah," \*Explorer: Jurnal Sains dan Teknologi\*, vol. 9, no. 3, pp. 132–141, 2023. [Online]. Available: <https://journal.fkpt.org/index.php/Explorer/article/view/881>. [Accessed: Dec. 27, 2024].
- [5] M. A. Hassan, R. S. Ahmed, and M. H. Khan, "Real-Time Gender and Age Detection Using Convolutional Neural Networks," \*2024 IEEE International Conference on Artificial Intelligence and Machine Learning (AIML)\*, 2024, pp. 123–128. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/10455315/>. [Accessed: Dec. 27, 2024].
- [6] F. Zhang and H. Li, "Fine-Tuning VGG16 for Age and Gender Prediction," \*2024 IEEE Symposium on Image Processing and Analysis (SIPA)\*, 2024, pp. 45–50. [Online]. Available: <https://ieeexplore.ieee.org/abstract/document/10455913/>. [Accessed: Dec. 27, 2024].